

Im main-folder ist das main-script "dualmodel_cusum.py":

1. LOAD VIRTUAL FLOWS FOR THE DUAL MODEL: Das ist das KWB interface data set, wobei man entweder 'data_09_virtual_flows.csv' oder 'data_08_virtual_flows_uncorrected.csv' nehmen kann. Meiner Meinung nach sehen die Statistiken für die unkorrigierten Flows besser aus.
2. GROUND TRUTH OF THE LEAKAGES: Dieses dictionary beinhaltet pipe_id: (leak start, leak fix, DMA in dem es liegt) für jedes zu Testende Leak
3. OPTIONALLY SELECT DIFFERENT THRESHOLD PARAMETERS: Zwei Parameter können gewählt werden, h_adn_set and h_corr_set: h_adn_set ist das Threshold für die Leckagen, für die die ad-Methode verwendet wird (also alle die, die in DMAs A und B liegen), und h_corr_set das Threshold für die corr-Methode (alle Leckagen, die im DMA C liegen). Der Unterschied besteht nur darin, dass in der corr-method die adn-method um einen Dekorrelierungsschritt erweitert wird, so dass die irregulären demands nicht so einen starken Einfluss auf die CUSUM-Statistik haben.
4. RUN CUSUM FOR EACH LEAK IN GROUND TRUTH DICT: Hier wird die CUSUM Methode für jedes Leak mit der Funktion 'f_CUSUM' ausgeführt. Ein Plot der jeweiligen CUSUM-Statistik wird noch mit 'f_plot_C' erstellt.

Die Funktionen f_CUSUM, f_plot_C sind in "cusum_utils.py" im_utils-folder definiert:

1. f_CUSUM extrahiert die zu untersuchende Zeitreihe (2 Wochen vor Leakstart bis Leakfix) für das zu untersuchende leak (definiert über pipe_id). Dabei nutze ich hier das Jahr 2019 als festgeschrieben, das kann man aber leicht anpassen. Je nachdem in welchem DMA das Leak liegt, wird dann entweder method adn oder method corr gestartet. Das Ergebnis ist der parameter detection, der entweder 'FP', 'FN', oder eine TTD ist.
2. f_plot_C ist nur die Plotting Funktion für die CUSUM-Statistik.
3. f_CUSUM_adn und f_CUSUM_corr sind die beiden CUSUM-Methoden, die genutzt werden. Dabei sind die Parameter in den Funktionen erklärt. Generell sind aber außer den threshold-Paramatern alle Inputs gefixt, und ich habe die Erweiterungen nicht beigefügt, da wir diese Einstellungen wahrscheinlich behalten werden, und wenn nur die Thresholds anpassen.

In dem data-folder sind die beiden CSV-files:

1. ('data_09_virtual_flows.csv', 'data_08_virtual_flows_uncorrected.csv') von dem Datenset.